# Analisi di dati di monitoraggio con Apache Spark

2023-2024


### Dataset di riferimento

date	serial_num ber	model	failure	vault_id	s9 power on hours	•••
2023-04- 01T00:00:00.00 0000	8HK2SSMH	HGST HUH721212AL N604	0	1113	38445.0	
2023-04- 01T00:00:00.00 0000	10B0A01UF97G	TOSHIBA MG07ACA14TA	0	1067	27425.0	
2023-04- 01T00:00:00.00 0000	5080A117F97G	TOSHIBA MG07ACA14TA	0	1095	18029.0	
2023-04- 01T00:00:00.00 0000	ZL2NG0QS	ST16000NM001 G	0	2010	6059.0	
	•••		•••	•••		

Dati forniti da Backblaze


### Architettura



















### Data-acquisition & Data-ingestion






figural: template per il Download e la Conversione dei dati

figura2: template per la Pulizia e il Filtraggio dei dati

### REST API per l'automatizzazione del flusso







### Query1





### Query2.1



#### read()

creazione dataframe iniziale.

### groupBy().agg(sum())

calcola fallimenti totali per ogni modello

### orderBy()

crea classifica in base ai fallimenti totali

#### show()

attuazione query



### Query2.2



dal dataframe iniziale filtra solo le entry con failure = 1

### groupBy().agg (count())

raggruppa per
'vault\_id' e calcola il
numero totale di
fallimenti per ogni
vault

### groupBy().agg (collect\_set())

raggruppa per
'vault\_id',
raccogliendo i modelli
distinti di hard disk
soggetti ad almeno un
fallimento

### join()

unisce i due dataframe precedenti

### orderBy()

ordina il dataframe precedente per creare una classifica

### show()

attuazione query



### Query3



### read()

creazione dataframe iniziale.

### filter().select(). distinct()

ottenere solo i serial\_number che hanno failure uguale a 1

### groupBy()

trova la data massima per ogni "model"

### join()

unisce i risultati del dataframe precedente con il dataframe originale

### leftJoin()

unisce il dataframe precedente con quello generato dalla filter

#### calculateStatistics()

calcola le statistiche sui "failed hard disk"

#### calculateStatistics()

calcola le statistiche sui "not failed hard disk"


#### union()


unisce i dataframe delle statistiche

### show()

attuazione query

### Data-visualization





Distribution of Operating Hours for Hard Disks with and without Failures											
# failure	min	25th_percentile	50th_percentile	75th_percentile	max	count					
1	522	27781	38702	51965	71608	265					
0	0	15119	22650	42066	87702	242644					

### Specifiche:


- 5 esecuzioni di ogni query
- configurazione con 1,2,3,4 worker

#### Caratteristiche macchina:

- {Processore}: 11th Gen Intel(R) Core(TM) i7-1165G7 @ 2.80GHz, 2803 Mhz, 4 core, 8 processori logici
- {Memoria fisica installata (RAM)}: 16,0 GB
- {SO}: Microsoft Windows 11 Pro

## Valutazione delle Performance





### Grazie per l'attenzione!